

畳み込みニューラルネットワークを用いた 福島県における橋梁のコンクリート部材の 変状検出

渡部 洸太郎[†] 佐竹 祐里奈^{††} 和泉 勇治[†]
子田 康弘[†] 中村 和樹[†]

近年、橋梁の老朽化が進行する中で、点検作業の省人化や省力化が求められている。本研究では、福島県が平成 28 年度に実施した道路橋点検の状況写真を元にしたトレーニングデータを用いて、CNN による橋梁のコンクリート部材の変状検出器となる学習モデルを構築した。本研究においては、先行研究で用いられた AlexNet を含め 8 種類のネットワークアーキテクチャを適用して各学習モデルを構築した。交差検定法を用いた評価の結果、鉄筋露出および漏水クラスにおいては AlexNet、剥離クラスにおいては VGG16、遊離石灰クラスにおいては MobileNetV2 を適用して学習モデルを構築することにより、本論文で検討した範囲においては分類正解率を最も高めることができることが示唆された。

Detection for concrete component deteriorations of a bridge in Fukushima Prefecture using a Convolutional Neural Network

Kotaro Watanabe[†], Yurina Satake^{††}, Yuji Waizumi[†]
Yasuhiro Koda[†] and Kazuki Nakamura[†]

It is important to improve the efficiency of bridge inspections as bridges have been aging in recent years. This study developed CNN-based models to detect damages in concrete bridge using photographs of road bridge inspection results in Fukushima Prefecture in 2016. Eight architectures, including AlexNet used in previous research were developed in this study. Cross-validation result suggested that the accuracies of the exposed rebar and water leakage, spalling, and efflorescence classes were improved by the learning models using AlexNet, VGG16, and MobileNetV2, respectively. Thus, the classification accuracy can be maximized by developing a learned model with an appropriately selected network architecture for each damage class.

1. はじめに

日本には約 73 万の道路橋が存在しており、近年ではその老朽化が懸念されている。具体的には、建設から 50 年を超える 2 m 以上の道路橋の割合は、2032 年時点で全体の約 6 割に達すると国土交通省が予測している¹⁾。また、全体の約 9 割の道路橋を地方公共団体が管理²⁾しているが、地方公共団体は道路橋の点検が可能な人材が不足しているため、点検の省人化や省力化が求められている。

以上の背景から、点検の省人化や省力化を実現する新たな手法として、機械学習の 1 種であるディープニューラルネットワークを適用することは、有効性の高い点検手法になると考えられる。先行研究³⁾では、道路橋のコンクリート部材の変状検出を、画像認識に特化した畳み込みニューラルネットワークにより、学習モデルに適用するネットワークアーキテクチャには AlexNet を採用することで行った。AlexNet は 2012 年に開発されたが、近年では様々なネットワークアーキテクチャが開発されている。

本研究では道路橋のコンクリート部材の分類正解率の向上を目的とし、道路橋のコンクリート部材の変状検出に適しているネットワークアーキテクチャを明らかにすることを目的とする。そのため、複数のネットワークアーキテクチャを適用した学習モデルを構築することで、先行研究で用いられた AlexNet による評価結果と、本研究で用いる複数のネットワークアーキテクチャによる評価結果を比較することにより、ネットワークアーキテクチャによる分類正解率の違いを調べた。また、転移学習という学習方法を用いることで転移学習モデルを構築し、転移学習を行っていない学習モデル（以降スクラッチ学習モデルと呼ぶ）と分類正解率を比較した。

2. 研究対象・使用データ

本研究は、福島県内の道路橋のコンクリート部材を研究対象として、平成 28 年度に福島県が実施した道路橋点検結果³⁾における状況写真 3679 画像から、近接撮影による道路橋のコンクリート部材の画像を選定して使用した。ここで、建設事務所の所管区域毎にトレーニングデータを構築した、具体的には、会津地区、南会津地区、喜多方地区、あぶくま地区、石川地区、三春地区、須賀川地区、県北地区、県中地区、県南地区、いわき地区、相双地区の計 12 地区の状況写真からそれぞれ、912、377、325、141、98、298、130、350、60、302、303、383 の元画像を抽出して、本研究における学習モデル構築のためのトレーニングデータとした。

[†]日本大学工学部情報工学科
Department of Computer Science, College of Engineering, Nihon University

^{††}日本大学大学院工学研究科
Graduate School of Engineering, Nihon University

表 1 各ラベルのブロック画像数

	データ数
鉄筋露出	4212
剥離	17930
遊離石灰	41996
漏水	10246




図 1 各ラベルのブロック画像例

3. 解析方法

3.1 ブロック画像の作成

学習モデル構築に入力するトレーニングデータは、元画像を 128×128 ピクセルを小領域とするブロック画像に分割し、画像から 81 ブロックの画像を作成した。作成したブロック画像に前処理として、道路橋の構成要素以外の学習には必要のない情報を含むブロック画像をトレーニングデータから除外した。このような前処理を施した後に、道路橋点検において検出の必要性の高い変状である、鉄筋露出、剥離、遊離石灰、漏水の 4 種類のラベルをブロック画像に付与した。各変状におけるブロック画像数を表 1 に示し、各ラベルの変状の事例を図 1 に示す。

3.2 学習モデルの構築

本研究は、道路橋のコンクリート部材の変状検出にディープニューラルネットワークを適用し、使用するネットワークアーキテクチャは、MobileNetV2, ResNet18, DenseNet121, VGG16, EfficientNetB0, ResNeXt50, ConvNeXt-Tiny の 7 種類である。これらのネットワークアーキテクチャを使用して、スクラッチ学習モデルを構築した。さらに、ImageNet-1K で事前学習された重みに基づき、鉄筋露出、剥離、遊離石灰、漏水のトレーニングデータを用いて転移学習モデルを構築した。各学習モデルの出力層は、入力層と同様に 4 と設定した。

構築した学習モデルは、交差検定法を用いて評価した。具体的には、12 地区のトレーニングデータから 1 地区を使用して学習モデルを構築する場合、残る 11 地区のデータを未知のデータとして、構築した学習モデルを評価した。スクラッチ学習と転移学習によって、各地区の学習モデルをネットワークアーキテクチャ毎に 12 モデル構築するため、交差検定法により計 168 モデルの評価結果を得る。

4. 解析結果

4.1 Epoch の決定

本研究のスクラッチ学習モデルおよび転移学習モデルでは、初期の学習率を 0.0001 とした。また、学習モデルにおける Epoch は次に示す手順により決定した。はじめに、学習モデルの構築に使用する地区のトレーニングデータの 20% を検証用データとして分割した。つぎに、検証用データを学習には使用しない未知データとして、1Epoch 毎に交差エントロピー誤差を用いて検証損失を算出した。最終的には、算出した検証損失が最も低かった Epoch を導出し、その時点での Epoch を最終的な学習モデルの Epoch と決定した。以上により決定した各学習モデルの Epoch を表 2 に示す。

4.2 スクラッチ学習モデルの評価結果

ネットワークアーキテクチャ毎に構築したスクラッチ学習モデルの評価結果である各クラスの平均正解率を図 2 に示し、先行研究で得られた評価結果は AlexNet として示した。この図から、各クラスにおいて正解率が最も高いスクラッチ学習モデルは、鉄筋露出クラスが 38.8% で AlexNet、剥離クラスが 43.5% で VGG16、遊離石灰クラスが 85.6% で MobileNetV2、漏水クラスが 36.5% で AlexNet であった。また、総合精度には、MobileNetV2 が 64.2% で最も高かった。

4.3 転移学習モデルの評価結果

ネットワークアーキテクチャ毎に構築した転移学習モデルの評価結果である各クラスの平均正解率を図 3 に示した。この図から、各クラスにおいて正解率が最も高い転移学習モデルは、鉄筋露出クラスが 42.66% で ConvNeXt-Tiny、剥離クラスが 43.93%

表 2 各学習モデルの Epoch 数

	会津	南会津	喜多方	あぶくま	石川	三春
ConvNeXt-Tiny	13	14	15	22	17	15
DnseNet121	9	25	16	35	30	10
EfficientNetB0	9	9	7	7	10	8
MobileNetV2	12	7	9	6	13	10
ResNet18	6	8	6	6	5	5
ResNeXt50	9	21	15	17	24	11
VGG16	8	14	15	23	13	15

	須賀川	県北	県中	県南	いわき	相双
ConvNeXt-Tiny	23	22	16	14	10	15
DnseNet121	23	22	41	14	26	11
EfficientNetB0	12	10	11	6	7	8
MobileNetV2	10	14	16	11	15	9
ResNet18	4	5	4	5	8	6
ResNeXt50	17	18	18	16	19	17
VGG16	13	11	19	10	16	15

で ConvNeXt-Tiny, 遊離石灰クラスが ResNet18 で 86.93%, 漏水クラスが ConvNeXt-Tiny で 51.21%であった。また, 総合精度については ConvNeXt-Tiny が 68.3 で最も高かった。

5. 考察

本研究で構築したスクラッチ学習モデルについて, 各クラスにおける分類正解率の最も高い及び最も低いネットワークアーキテクチャの差を比較することで, トレーニングデータ数とネットワークアーキテクチャの関係を調べた。鉄筋露出クラスでは, 正解率が最も高い AlexNet と, 正解率が最も低い ConvNeXt-Tiny の差が 16.1 ポイントであった, 剥離クラスでは, 正解率が最も高い VGG16 と最も低い ConvNeXt-Tiny の差が 13.8 ポイントであった。遊離石灰クラスでは, 正解率が最も高い MobileNetV2 と最も低い DenseNet121 の差が 6.9 ポイントであった。漏水クラスでは, 正解率が最も高い AlexNet と最も低い MobileNetV2 の差が 15.4 ポイントであった。分類正解率の差が大きい順に, 鉄筋露出, 漏水, 剥離, 遊離石灰となった。ここで, 学習モデルのトレーニングデータ数は大きい順に, 鉄筋露出, 漏水, 剥離, 遊離石灰である。このことから, スクラッチ学習モデルにおいてはトレーニングデータ数が少ないほど, ネットワークアーキテクチャ間の分類正解率の差が大きいことが判明した。つまり, トレーニングデータ数が少なくても十分に汎化性能を発揮できるネットワークアーキテクチャと, 多量のトレーニングデータを学習しないと, 十分に汎化性能を発揮できないネットワークアーキテクチャの差を示唆している。




図 2 ネットワークアーキテクチャ毎に構築したスクラッチ学習モデルの評価結果




図 3 ネットワークアーキテクチャ毎に構築した転移学習モデルの評価結果

トワークアーキテクチャ間の分類正解率の差が大きいことが判明した。つまり, トレーニングデータ数が少なくても十分に汎化性能を発揮できるネットワークアーキテクチャと, 多量のトレーニングデータを学習しないと, 十分に汎化性能を発揮できないネットワークアーキテクチャの差を示唆している。

以上から, 本研究で構築した 7 種類のネットワークアーキテクチャによって構築された学習モデルに加えて先行研究で使用された AlexNet による分類正解率を比較した結果, 総合精度は MobileNetV2 による学習モデルが最も高いことが分かった。

本研究で構築した転移学習モデルとスクラッチ学習モデルの各クラスの分類正解

率を比較した結果、ConvNeXt-Tiny および ResNeXt50 を除く全てのアーキテクチャにおいて、転移学習モデルの分類正解率がスクラッチ学習モデルの分類正解率を下回る結果となった。とくに、鉄筋露出および剥離クラスにおいては、転移学習モデルの分類正解率がスクラッチ学習モデルと比較して 10 ポイント以上低下していることが確認された。Pan ら⁴⁾は、転移学習モデルの事前学習に使用するデータセットと、トレーニングデータのドメインが異なる場合に転移学習を行うと、ドメインの乖離によって学習モデルの性能を損なう「負の転移」が生じる可能性を指摘している。本研究においてドメインとは、画像データの特徴やそれらがデータセット内で出現する周辺確率分布を指す。このことから、本研究における ConvNeXt-Tiny および ResNeXt50 を除く転移学習モデルの鉄筋露出および剥離クラスの正解率の低下は、事前学習に使用された ImageNet-1K と本研究で使用したトレーニングデータにおけるドメインの乖離に起因するものと考えられる。

さらに、図 3 から ConvNeXt-Tiny と ResNeXt50 を適用した場合は、スクラッチ学習モデルと比較して、全てのクラスにおいて転移学習モデルの分類正解率の向上が確認できる。これは、両ネットワークアーキテクチャの畳み込み層のチャンネル数（画像から特定の視覚情報を抽出した特徴のバリエーション）が、他のネットワークアーキテクチャと比較して多く、複数の特徴を捉えられていると考えられる。

また、ResNeXt50 による分類正解率の向上は、特徴抽出を複数の独立したグループで行うカーディナリティという構造によって、コンクリート部材の変状の特徴を相補的に抽出することで負の転移が抑制され、転移学習の有効性を引き出すことができたと考えられる。

本研究において整備したトレーニングデータは遊離石灰ラベルのトレーニングデータ数が他の 3 ラベルと比較して 2 倍以上多いため、総合精度に影響していると考えられる。そのため、データオーギュメンテーションによるトレーニングデータの拡張によって、トレーニング数の不均衡の解消を図ることで、道路橋のコンクリート部材の変状検出に好適であるネットワークアーキテクチャを明らかにできると考えられる。

6. まとめ

本研究では、平成 28 年度に福島県が実施した道路橋点検結果における、福島県の 12 地区の状況写真をトレーニングデータとする 7 種類のネットワークアーキテクチャを適用し、コンクリート部材の変状検出器となるスクラッチ学習モデルおよび転移学習モデルを構築した。




図 4 スクラッチ学習モデルと転移学習モデルの分類正解率の差

構築したスクラッチ学習モデルは、交差検定法を用いて先行研究で構築された AlexNet を用いたスクラッチ学習モデルの評価結果を含めた、8 種類のネットワークアーキテクチャによって構築されたスクラッチ学習モデルの評価結果を比較した。その結果、鉄筋露出および漏水クラスについては AlexNet、剥離クラスについては VGG16、遊離石灰クラスについては MobileNetV2 が最も高かった。

また、各クラスにおける分類正解率の最も高いまたは最も低いネットワークアーキテクチャの差を比較することで、トレーニングデータ数とネットワークアーキテクチャの関係を調べた。その結果、トレーニングデータ数によってネットワークアーキテクチャ毎の分類正解率に差ができると考えられた。

さらに、構築した転移学習モデルはスクラッチ学習モデルと同様に交差検定法を用いて評価を行い、7 種類のネットワークアーキテクチャによって構築された転移学習モデルの評価結果を比較した。その結果、鉄筋露出および剥離および漏水については ConvNeXt-Tiny が最も高く、遊離石灰については ResNet18 が最も高かった。

本研究で検討した範囲では、ConvNeXt-Tiny および ResNeXt50 を除くネットワークアーキテクチャを適用して転移学習モデルを構築した場合には、ドメインの乖離によって負の転移が発生すると考えられた。

7. 今後の課題

本研究で構築したスクラッチ学習モデルおよび転移学習モデルは、遊離石灰の正解率が他クラスと比較して顕著に高い傾向にあるが、トレーニングデータ数の不均衡に起因していると考えられた。そのため、トレーニングデータ数を拡張することによりトレーニングデータ数の不均衡を解消した上で、コンクリート部材のさらなる分類正解率の向上を目指す。

また、本研究では転移学習モデルの構築にあたって、事前学習データセットとして ImageNet-1K を適用していたが、本研究で使用しているトレーニングデータとのドメインの乖離によって負の転移が発生している可能性が示唆された。そのため、ImageNet-1K 以外のデータセットを適用することにより、学習モデルの汎化性能の向上を図りたい。

謝辞

本研究は平成 30 年度～令和 2 年度福島県産学連携ロボット研究開発支援事業の助成を受けると共に、本研究で使用了道路橋点検結果は福島県よりご提供いただいた。また、本研究は新和設計株式会社の高橋明彦氏と株式会社大地設計の神永秀明氏にご協力頂いた。

参考文献

- 1)国土交通省: 老朽化の現状・老朽化対策の課題, <https://www.mit.go.jp/road/content/001574275.pdf>.
- 2)小林弘明, 中村和樹, 和泉勇治, 子田康弘: CNN を用いたコンクリート橋の変状検出とトレーニングデータ数の関係, AI・データサイエンス論文集, 4 巻 3 号, p747-p756, 2023.
- 3)福島県: 平成 28 年度橋梁点検結果 (福島県管理道路), https://www.pref.fukushima.lg.jp/uploaded/lfie/481697_1239756_misc.pdf.
- 4)Pan, S. J. and, Yang, Q.: A Survey on Transfer Learning, IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING, vol22, No.10, pp.1345-1359 (2010).